

CHALLENGE | FORD

Data de entrega: 24/05

Equipe

Matéria	Responsáveis
Arquitetura Orientada a Serviços e Web Services	Renan e Camila
Mobile Development and IoT	Isabelle e Pedro
Testing, Compliance and Quality Assurance	Todos (video pitch: isabelle)
Cybersecurity	Renan e Camila
Inteligência Artificial & Machine Learning	Nicoli e o Claudio PAGO (+fiapo)

🌟 Desafio 01 – Inteligência Competitiva Automotiva

Problema

Coletar especificações técnicas de veículos concorrentes consome ~1 hora por versão de forma manual, com alta probabilidade de imprecisão. O analista navega em sites, assiste vídeos, liga para concessionárias e preenche planilhas à mão — que ficam desatualizadas rapidamente.

Impacto no negócio

Decisões de posicionamento de produto baseadas em dados imprecisos ou desatualizados afetam a estratégia comercial e a argumentação de vendas da Ford frente à concorrência.

Resumo do Projeto

Solução

O SpecRadar é uma plataforma de inteligência competitiva automotiva que elimina o gargalo de coleta manual. O analista consulta qualquer veículo concorrente em linguagem natural ou via formulário estruturado e recebe em segundos uma ficha técnica padronizada, sempre no mesmo formato.

Dois modos de interação sobre a mesma base técnica:

- **Modo chat:** consultas em linguagem natural e cruzamento de dados já no repositório histórico (ex: 'Qual pick-up concorrente tem mais torque abaixo de R\$ 300 mil?')
- **Modo formulário:** entrada estruturada de Marca, Modelo, Versão e lista de atributos — exatamente como o brief da Ford específica — com saída em tabela exportável

Diferencial central:

- Confidence score por campo: cada spec retorna com confiança (alta / inferida / não encontrado), URL da fonte e data de verificação — nenhum sistema de dados automotivos existente oferece isso
- Repositório histórico acumulativo: cada consulta enriquece o banco coletivo, permitindo comparações instantâneas sem nova busca
- Sensor de demanda preditiva: monitora menções públicas de veículos concorrentes e atualiza o banco preventivamente antes das perguntas chegarem

Objetivo

- Reduzir de ~60 min para menos de 10 segundos o tempo de coleta de specs por versão
- Garantir padronização e rastreabilidade de todos os dados coletados
- Construir repositório comparativo permanente de especificações da concorrência
- Validação: sistema deve entregar corretamente todas as specs da Ford Ranger Raptor (caso de teste oficial do brief)

Links

[Sprint 1 | Testing, Compliance and Quality Assurance](#)



Status geral

Tarefa	Responsável	Matéria	Status
Documentação Swagger / README da API	Renan e Camila ▾	Java ▾	Não iniciado ▾
Implementação da API RESTful de extração	Renan e Camila ▾	Java ▾	Não iniciado ▾
Endpoint de comparação entre veículos	Renan e Camila ▾	Java ▾	Não iniciado ▾
Confidence score + verificado_em por campo	Renan e Camila ▾	Java ▾	Não iniciado ▾
App React Native — tela de consulta (chat)	Pedro e Isabelle ▾	Mobile ▾	Não iniciado ▾
App React Native — tela formulário + histórico	Pedro e Isabelle ▾	Mobile ▾	Não iniciado ▾
Tela de comparação visual lado a lado	Pedro e Isabelle ▾	Mobile ▾	Não iniciado ▾
Pitch estruturado (10–15 slides)	Todos ▾	QA ▾	Não iniciado ▾
Business Model Canvas	Todos ▾	QA ▾	Não iniciado ▾
Quadro de Valor (stakeholders + métricas)	Todos ▾	QA ▾	Não iniciado ▾
Arquitetura TOGAF no Archi (.archimate)	Todos ▾	QA ▾	Não iniciado ▾
Vídeo pitch (até 3 min, todos participam)	Isabelle ▾	QA ▾	Não iniciado ▾
JWT + RBAC + rate limiting	Renan e Camila ▾	Cyber ▾	Não iniciado ▾
Sanitização de entradas + tratamento de erros	Renan e Camila ▾	Cyber ▾	Não iniciado ▾
Logs de auditoria + criptografia em repouso	Renan e Camila ▾	Cyber ▾	Não iniciado ▾
Alinhar escopo AI/ML com professor	Nicoli ▾	IA & ML ▾	Não iniciado ▾
Jupyter Notebook + relatório PDF	Nicoli ▾	None ▾	Não iniciado ▾
Demo ao vivo com Ranger Raptor (ensaio)	Todos ▾	None ▾	Não iniciado ▾

Arquitetura Orientada a Serviços e Web Services

Responsáveis: Renan e Camila

O que a matéria pede

Integração por Web Services (50%)

- Desenho de arquitetura contendo os componentes que pretendem usar (10%)
- Implementação de APIs RESTful ou SOAP para comunicação entre sistemas (20%)
- Uso adequado de métodos HTTP (10%)
- Documentação das APIs com README ou Swagger como um contrato com os endpoints (10%)

Arquitetura Orientada a Serviços (SOA) (20%)

- Organização modular baseada em serviços independentes e reutilizáveis (10%)
- Separação clara entre camadas de apresentação, serviço e dados (10%)

Padrões e Boas Práticas (15%)

- Adoção de padrões como REST, SOAP, JSON, XML, WSDL (8%)
- Tratamento adequado de erros e exceções nos serviços (7%)

Conexão com banco de dados (15%)

- Dependências e configurações para conexão (8%)
- Controle de migrações (7%)

O que fazer no SpecRadar

1. Documentar todos os endpoints no Swagger (vale 10% — não entregar é eliminatório)

- POST /api/v1/specs/query — entrada: { marca, modelo, versao, atributos[] } | saída: ficha padronizada com confidence + fonte + verificado_em
- GET /api/v1/specs/compare?v1=X&v2=Y&atributos=a,b — retorna os dois registros do banco lado a lado com diff automático
- POST /api/v1/specs/from-pdf — upload de PDF de catálogo, retorna a ficha extraída
- GET /api/v1/specs/history — lista registros no banco com filtros de marca/modelo
- Documentar: método HTTP, path, parâmetros, body de exemplo, resposta 200 e respostas de erro (401, 404, 422, 500)

2. Separação de camadas (vale 10% — desenhar e citar no documento)

- Camada de apresentação: controllers da API (recebem requests, devolvem responses padronizados)
- Camada de serviço: lógica de extração, normalização de atributos, cálculo de confidence score, sensor de demanda
- Camada de dados: repositório de specs no banco, histórico de consultas, controle de migrações com Alembic

3. Tratamento de erros obrigatório em todos os endpoints

- Veículo não encontrado → 404 com campo 'sugestoes_similares'
- Atributo sem dado disponível → campo retornado como { valor: null, confiança: 'nao_encontrado' } — nunca omitido
- Falha de fonte externa (timeout) → 503 com mensagem genérica, sem expor tecnologia interna
- Entrada malformada → 422 com lista de campos inválidos

4. Diferencial: endpoint de comparação direta entre dois veículos

- GET /api/v1/specs/compare retorna os dois veículos do banco lado a lado
- Inclui campo 'vencedor' por atributo (qual dos dois tem valor superior)
- Valida o repositório histórico como feature real de inteligência competitiva
- Simples de implementar se o banco já existe — alto impacto na banca

Mobile Development and IoT

Responsáveis: Isabelle e Pedro

O que a matéria pede

- App mobile multiplataforma (iOS e Android) com React Native + Expo
- Navegação com Expo Router
- Consumo de APIs assíncronas com tratamento de loading e erro
- Integração com pelo menos uma fonte de dados externa via API
- Diferenciais avaliados: notificações, armazenamento local, integração com sensores
- Avaliação: qualidade técnica, consistência de UX, aderência ao problema de negócio

O que fazer no SpecRadar

1. Especificar React Native + Expo Router explicitamente (obrigatório)

- Nomear a stack no documento: React Native com Expo SDK + Expo Router para navegação
- Estrutura de tabs: (1) Chat / (2) Formulário / (3) Comparar / (4) Histórico
- Cada tab é uma rota do Expo Router — mostrar a estrutura de arquivos no documento

2. Consumo assíncrono da API com tratamento completo de estados

- useState para dados, loading e erro em cada tela de consulta
- Loading spinner visível durante chamada à API
- Mensagem de erro amigável quando a API falha ou o veículo não é encontrado
- Timeout de 15s com feedback ao usuário se a extração demorar

3. Armazenamento local com AsyncStorage (diferencial avaliativo)

- Salvar últimas 10 consultas no AsyncStorage do dispositivo
- Tela de histórico offline — funciona sem conexão
- Útil em concessionárias com internet instável — argumento de negócio real

4. Tela de comparação visual lado a lado (maior diferencial do app)

- Selecionar dois veículos do histórico e comparar atributos em tabela lado a lado
- Células coloridas: verde para o veículo com valor superior em cada atributo
- Demonstra domínio de componentes React Native + estado + API em uma tela só
- Conecta diretamente ao endpoint GET /specs/compare da API

5. Consistência de UX e narrativa clara de produto

- Tela inicial com busca rápida proeminente — o analista vê o valor em 5 segundos
- Ficha de specs com indicador visual de confidence: verde = verificado, laranja = inferido, cinza = não encontrado
- Botão de exportar/compartilhar a ficha em CSV ou texto

Testing, Compliance and Quality Assurance

Responsáveis: Todos – Vídeo: Isabelle

O que a matéria pede

- Pitch de projeto: 10–15 slides + vídeo de até 3 minutos (todos participam)
- Business Model Canvas completo (9 blocos)
- Quadro de Valor: stakeholders, expectativas, métricas de negócio e de qualidade
- Arquitetura TOGAF no Archi — 4 visões obrigatórias + arquivo .archimate
- Entrega pelo Teams: apresentação + link do vídeo (no slide 1) + arquivo .archimate

O que fazer no SpecRadar

1. Pitch estruturado — estrutura obrigatória dos slides

- Slide 1: Nome SpecRadar + nomes e RMs de todos + link do vídeo
- Slide 2: Problema — 1h por versão, processo manual, imprecisão (dado documentado pela Ford)
- Slide 3: Escala do problema — não é exclusivo da Ford; citar empresas e mercados que enfrentam isso
- Slide 4: Solução — SpecRadar em 3 linhas: o que é, como funciona, para quem
- Slide 5: Benchmarking — iCarros, FIPE, Quatro Rodas, S&P Global não oferecem: extração por atributos + confidence score + repositório acumulativo
- Slide 6: Diferencial competitivo — confidence score por campo + sensor de demanda preditiva + repositório histórico
- Slide 7: Critérios de qualidade — precisão $\geq 95\%$ dos campos, tempo de resposta $< 10s$, disponibilidade $\geq 99\%$
- Slide 8: Riscos — hallucination de LLM, desatualização de dados, bloqueio de fontes web
- Slide 9: Métricas de sucesso — tempo de consulta, taxa de campos preenchidos vs. vazios, NPS do analista
- Slide 10: Roadmap — o que entrega na Sprint 1 vs. evoluções futuras (multimodal, PDF, imagem)

2. Business Model Canvas — 9 blocos para o SpecRadar

- Clientes: equipes de Product Marketing e Inteligência Competitiva da Ford
- Canais: app mobile (Expo) + interface web + API interna Ford
- Valor: eliminar 1h/versão de trabalho manual; dados padronizados, auditáveis e comparáveis
- Atividades-chave: manutenção do pipeline de extração; curadoria do banco histórico; sensor de demanda
- Recursos: infraestrutura cloud, modelo LLM, equipe de dados e desenvolvimento
- Parceiros: provedores de LLM (OpenAI/Anthropic), cloud (AWS/Azure/GCP)
- Custos: tokens de LLM por consulta, hospedagem cloud, manutenção do pipeline
- Receita/economia: redução de horas de analista $\times$ custo/hora $\times$ volume mensal
- Impactos de falha: decisões de posicionamento erradas, custo de retrabalho, risco reputacional

3. Quadro de Valor — stakeholders com métricas duplas (negócio + qualidade)

- PM Ford | espera: specs rápidas e corretas | entrega: ficha em $<10s$ | métrica negócio: -80% tempo/versão | métrica qualidade: precisão $\geq 95\%$
- TI Ford | espera: integração segura e documentada | entrega: API REST + JWT + Swagger | métrica negócio: 0 incidentes de segurança | métrica qualidade: uptime $\geq 99\%$
- Liderança Ford | espera: redução de custo operacional | entrega: repositório histórico acumulativo | métrica negócio: horas economizadas/mês | métrica qualidade: disponibilidade da plataforma

4. Arquitetura TOGAF no Archi — 4 visões obrigatórias

- Visão de Arquitetura: objetivo estratégico (eliminar coleta manual) + requisitos funcionais e não-funcionais
- Arquitetura de Negócio: fluxo ATUAL (analista $\rightarrow$ busca manual $\rightarrow$ planilha) vs. fluxo COM SpecRadar (analista $\rightarrow$ app $\rightarrow$ ficha padronizada em $<10s$)
- Arquitetura de Sistema: componentes — app mobile, API gateway, serviço de extração, LLM, banco de specs, módulo de diff, sensor de demanda
- Arquitetura de Tecnologia: React Native + FastAPI + PostgreSQL + Redis cache + provider LLM + cloud hosting
- Entregar arquivo .archimate junto com a apresentação pelo Teams

Cybersecurity

Responsáveis: Renan e Camila

O que a matéria pede

1. Segurança de Entrada e Validação de Dados (20 pts)

- Validação de entradas: sanitização contra SQL Injection, XSS, command injection
- Normalização de parâmetros de API: marca, modelo, versão e atributos com padrões definidos
- Limitação de tamanho e formato: prevenir payload flooding e buffer overflow
- Tratamento seguro de erros: mensagens sem stack trace ou tecnologia interna

2. Autenticação e Autorização (20 pts)

- JWT com expiração, assinatura forte e renovação controlada
- RBAC: diferenciar analista (consulta/exporta) de admin (gerencia banco e configurações)

3. Proteção de APIs e Serviços (20 pts)

- HTTPS/TLS 1.2+ obrigatório em todos os endpoints
- Rate limiting e throttling: 60 req/min por usuário
- CORS configurado para aceitar apenas domínios autorizados
- Assinatura/verificação de integridade de payloads (5 pts extras)

4. Segurança de Dados e Privacidade (25 pts)

- Criptografia de dados sensíveis em repouso (specs no banco: AES-256)
- Política de retenção: dados com 12+ meses sem acesso são arquivados, não deletados
- Proteção contra exposição acidental: sem logs sensíveis, dumps ou endpoints não documentados

5. Monitoramento, Logs e Auditoria (15 pts)

- Logs estruturados com rastreabilidade: usuário + timestamp + ação + veículo consultado
- Monitoramento de eventos suspeitos: acessos indevidos, falhas repetidas, consultas massivas
- Trilha de auditoria para ações críticas: alterações de configuração, consultas em lote

O que fazer no SpecRadar

Validação de entrada com Pydantic (FastAPI)

- Classe SpecQuery: marca (str, 2–50 chars, só letras), modelo (str, 2–80), versao (str, 2–80), atributos (lista, 1–20 itens)
- Rejeitar qualquer input fora do padrão com 422 Unprocessable Entity
- Sanitizar inputs antes de passar ao LLM — prompt injection é o risco específico desta solução

JWT + RBAC

- Token de acesso: expiração 8h | Token de refresh: expiração 7d
- Role ANALYST: GET /specs, POST /specs/query, GET /specs/compare, GET /specs/history
- Role ADMIN: DELETE /specs/:id, PUT /specs/config, POST /specs/bulk-import
- Nenhum endpoint protegido aceita request sem Authorization: Bearer <token> válido

Rate limiting + HTTPS + CORS

- 60 requisições por minuto por usuário autenticado (evita scraping do banco)
- TLS 1.2+ obrigatório — certificate pinning no app mobile é diferencial
- CORS: aceitar apenas domínios da Ford (ford.com.br, ford.com) + localhost:3000 em dev

Logs de auditoria seguros

- Cada consulta registra: user_id (hash, não email), timestamp, marca+modelo consultados, campos solicitados
- Logs NUNCA contêm: email, nome, token JWT, stack trace, resposta completa da API
- Alertas automáticos: >100 consultas em 5 minutos por usuário → bloquear e notificar admin

Inteligência Artificial & Machine Learning

Responsáveis: Nicoli

O que a matéria pede (Desafio 2 — escopo original)

- Base 1 (histórico completo): segmentação comportamental com aprendizado não supervisionado (clustering)
- Base 2 (dados do momento da compra): classificação preditiva supervisionada — SEM variáveis futuras
- Quatro perfis hipotéticos: Fiel, Abandono, Esquecido, Econômico — verificar se dados sustentam
- Regra crítica: usar variáveis futuras na classificação = data leakage = trabalho invalidado
- Entregáveis: Jupyter Notebook (.ipynb) + relatório PDF com leitura executiva dos resultados

Segmentação e Classificação de Clientes: Ford (Dados Sintéticos)

A Ford deseja aumentar a retenção de clientes na rede oficial de manutenção, ou seja, aumentar a probabilidade de que um cliente retorne às concessionárias e oficinas autorizadas ao longo do ciclo de vida do veículo. O principal desafio desse problema é que, no momento da compra, ainda não se conhece o comportamento futuro do cliente. Dessa forma, o projeto propõe o uso de técnicas analíticas para identificar padrões de comportamento e, posteriormente, prever esses padrões utilizando apenas informações iniciais.

O trabalho será dividido em duas frentes complementares. A primeira consiste em uma etapa de segmentação comportamental, utilizando técnicas de aprendizado não supervisionado sobre dados históricos completos, com o objetivo de identificar perfis reais de clientes. A segunda consiste em uma etapa de modelagem preditiva, na qual os perfis encontrados serão transformados em uma variável-alvo e um modelo supervisionado será treinado para prever, no momento da compra, a qual perfil um novo cliente provavelmente pertence.

Os dados utilizados neste trabalho são sintéticos, ou seja, foram gerados artificialmente para simular um cenário real de negócio. Apesar disso, eles foram construídos de forma a refletir padrões plausíveis de comportamento de clientes. As bases de dados podem ser obtidas diretamente com o professor da disciplina.

Do ponto de vista de negócio, foi levantada uma hipótese inicial de segmentação contendo quatro perfis principais. O cliente fiel é aquele que retorna consistentemente para realizar manutenção na rede oficial, independentemente de fatores como preço ou conveniência. O cliente de abandono é aquele que realiza no máximo a primeira revisão e rapidamente deixa a rede, buscando alternativas externas mais baratas. O cliente esquecido é aquele

que perde o timing da manutenção, tenta retornar depois e acaba se frustrando com a marca. Já o cliente econômico mantém algum relacionamento com a rede, mas é altamente sensível a preço, promoções e condições comerciais. É importante destacar que esses perfis são apenas uma hipótese simulada, e cabe ao grupo verificar se os dados sustentam essa estrutura.

O trabalho utilizará duas bases distintas. A Base 1 contém o histórico completo dos clientes, incluindo informações observadas após a compra do veículo, e deve ser utilizada exclusivamente para a etapa de segmentação, pois permite identificar padrões reais de comportamento. Já a Base 2 contém apenas informações disponíveis no momento da compra e deve ser utilizada na etapa de classificação preditiva, simulando o cenário real em que a concessionária precisa tomar decisões sem conhecer o futuro do cliente.

Existe uma regra crítica no projeto: na etapa de classificação, é terminantemente proibido utilizar qualquer variável que represente comportamento futuro do cliente. Isso inclui informações como revisões realizadas, tempo até manutenção, gastos ou qualquer indicador pós-compra. O uso dessas variáveis caracteriza data leakage e invalida completamente o modelo. Portanto, a modelagem supervisionada deve ser feita exclusivamente com variáveis disponíveis no momento da compra.

Em termos de entregas, o trabalho começa com a preparação dos dados, incluindo análise exploratória, tratamento de valores faltantes, inconsistências e variáveis categóricas. Em seguida, deve ser realizada a segmentação dos clientes utilizando a Base 1, com escolha e justificativa das variáveis, aplicação de técnicas de clustering e definição do número de segmentos. Esses segmentos devem ser analisados, interpretados e traduzidos em perfis de negócio claros, evitando nomenclaturas genéricas como “Cluster 0” ou “Cluster 1”.

Após a definição dos perfis, o grupo deverá propor estratégias de retenção específicas para cada segmento, demonstrando coerência entre comportamento observado e ação sugerida. Em seguida, os clusters devem ser transformados em uma variável-alvo para permitir a etapa de classificação supervisionada. Utilizando a Base 2, o grupo deverá então treinar um modelo preditivo, realizando tratamento de variáveis, separação de treino e teste e avaliação com métricas adequadas, como accuracy, precision, recall, F1-score e matriz de confusão.

Por fim, espera-se uma leitura executiva dos resultados, indicando quais segmentos foram identificados, quais apresentam maior risco de evasão, quais são mais sensíveis a ações comerciais e quão bem o modelo consegue prever o perfil de novos clientes. O grupo também deve discutir como essa solução poderia ser aplicada no dia a dia da concessionária.

Como entregáveis finais, devem ser apresentados um Jupyter Notebook (.ipynb) contendo todo o desenvolvimento técnico e um relatório em PDF com os principais achados. Não serão aceitos trabalhos que utilizem variáveis futuras na classificação, misturem indevidamente as bases, apresentem clusters sem interpretação de negócio ou tragam conclusões sem suporte analítico.